Apache Spark
Introducción

Taller de Big Data

Agenda

- Apache Spark
- Estructura de datos: Spark RDD
- Operaciones: Transformaciones y Acciones
- Estructura de datos: Spark DataFrames

Apache Spark

¿Qué es Apache Spark?

- Un motor general para procesamiento a gran escala de datos.
- Ejecuta en Apache YARN, *standalone*, en Amazon EC2 o sobre Apache Mesos.
  - Aquí sólo veremos el funcionamiento *standalone*
- Soporta varios lenguajes de programación
  - Python, Scala, Java y recientemente R.

¿Por qué Apache Spark?

- Soporta Algoritmos Iterativos
  - Como algoritmos de grafos
- Exploración Iterativa
- Puede ejecutar en *batch.*
- Soporta *streaming.*

Historia

- Todo empezó con el proyecto **Mesos**, un *framework* distribuido de ejecución, realizado para una clase en UC Berkeley en 2009.
- **Spark** fué creado para probar **Mesos.**
- Fué tal su éxito que se abrió el código en 2010.

Funcionamiento

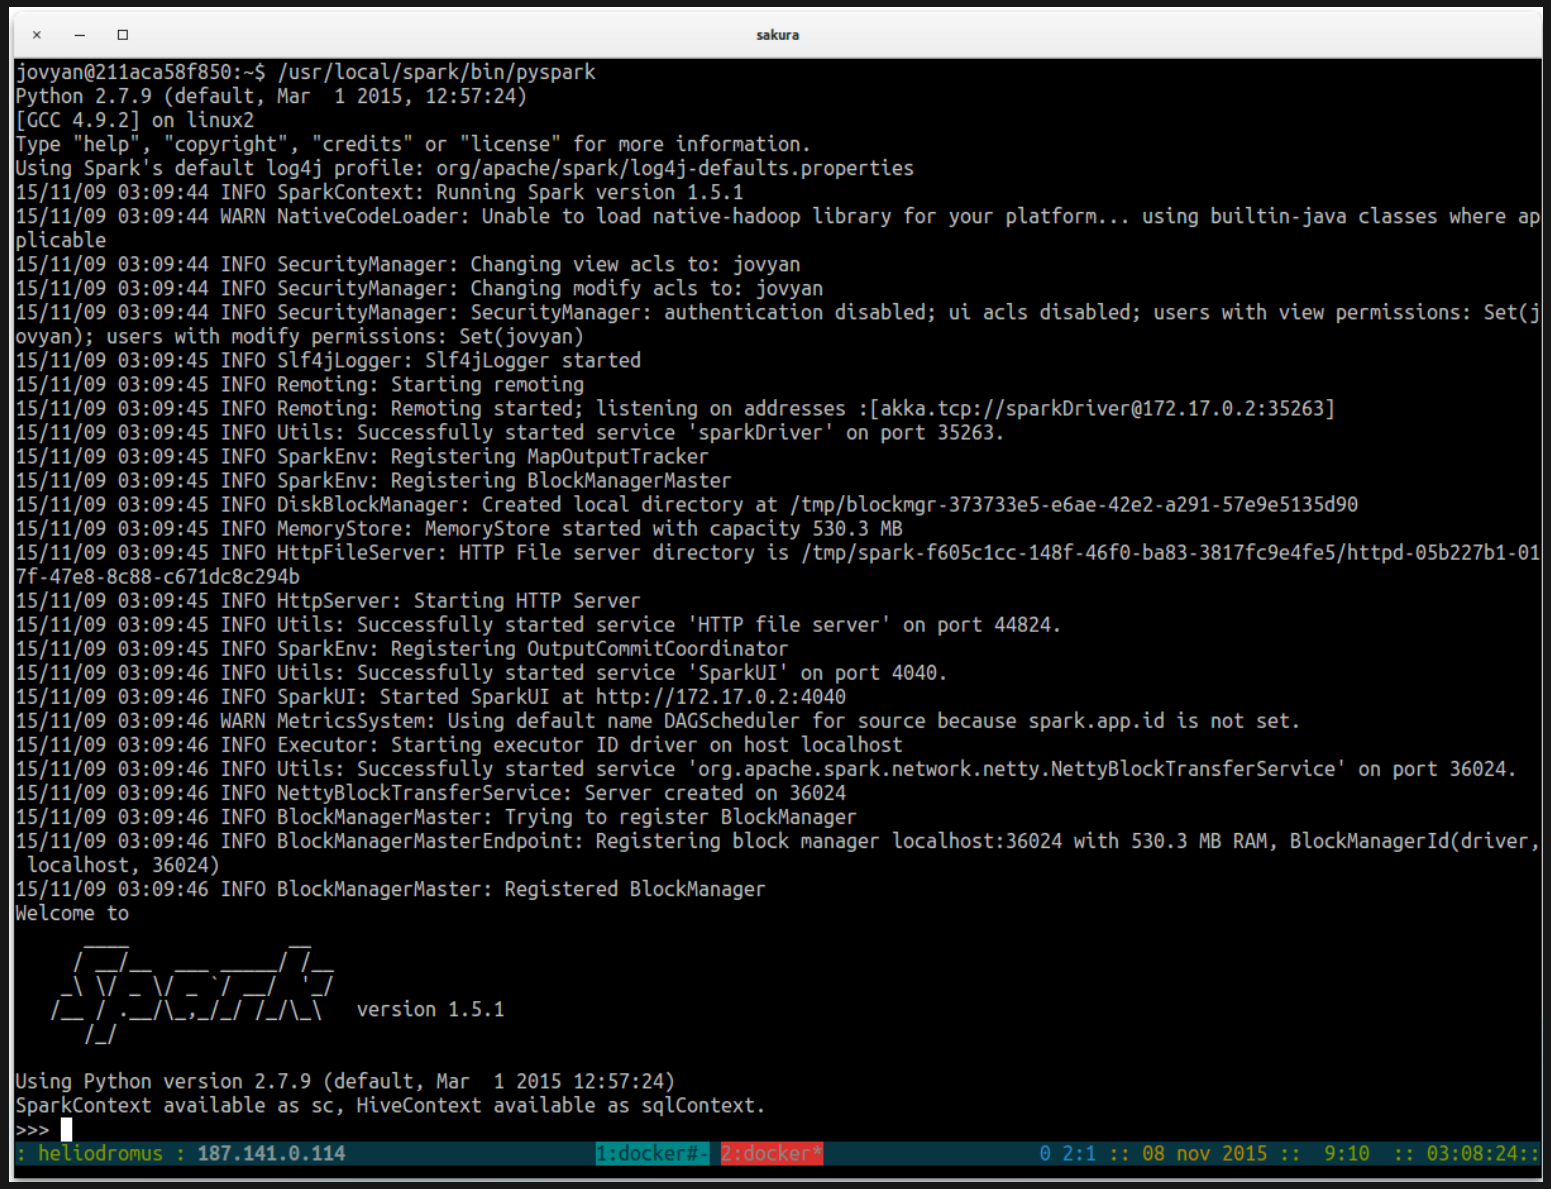

Modelo de Ejecución

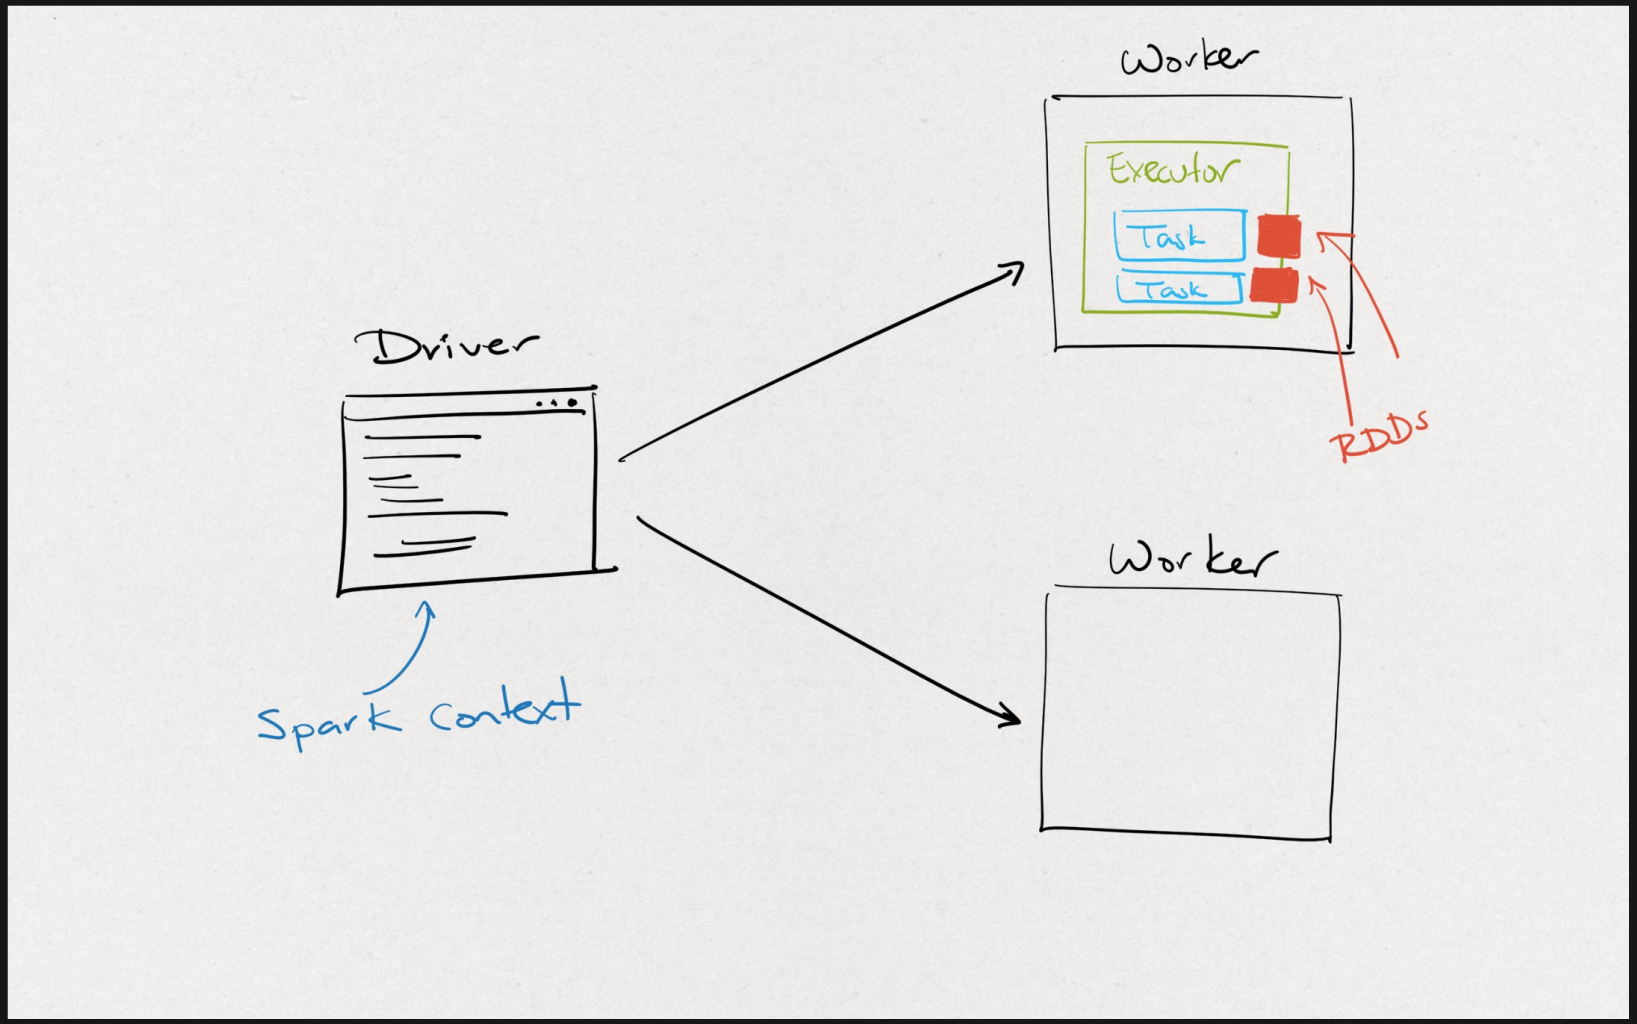

Ciclo de vida

- Crear un RDD a partir de datos externos
- Transformarlo *lazily* en nuevos RDDs usando **transformaciones.**
- Usa `cache()` en los RDDs que vayas a reutilizar
- Utiliza **acciones** para iniciar la ejecución en paralelo

Spark RDD

Spark RDD

- *Resilient Distributed Dataset*
- Abstracción que representa una colección de objetos de sólo lectura particionada a lo largo de varias máquinas.

Spark RDD: Ventajas

- Pueden ser reconstruidas gracias a su *linage.*
- Pueden ser manipuladas en paralelo.
- Están *cached* en memoria para su uso inmediato.
- Son almacenadas de manera distribuida.
- Contienen cualquier tipo de dato, incluidos los definidos por el programador.

Spark RDD: Operaciones

- Soportan dos tipos de operaciones:
  - **Transformaciones**
  - **Acciones**
- Las *transformaciones* construyen un nuevo RDD a partir del anterior.
  - El cual queda guardado en el *linage graph* (DAG)
- Las *acciones* calculan el resultado basado en el RDD.
- La diferencia es que las transformaciones son computadas de manera *lazy* y sólo son ejecutadas hasta la acción.

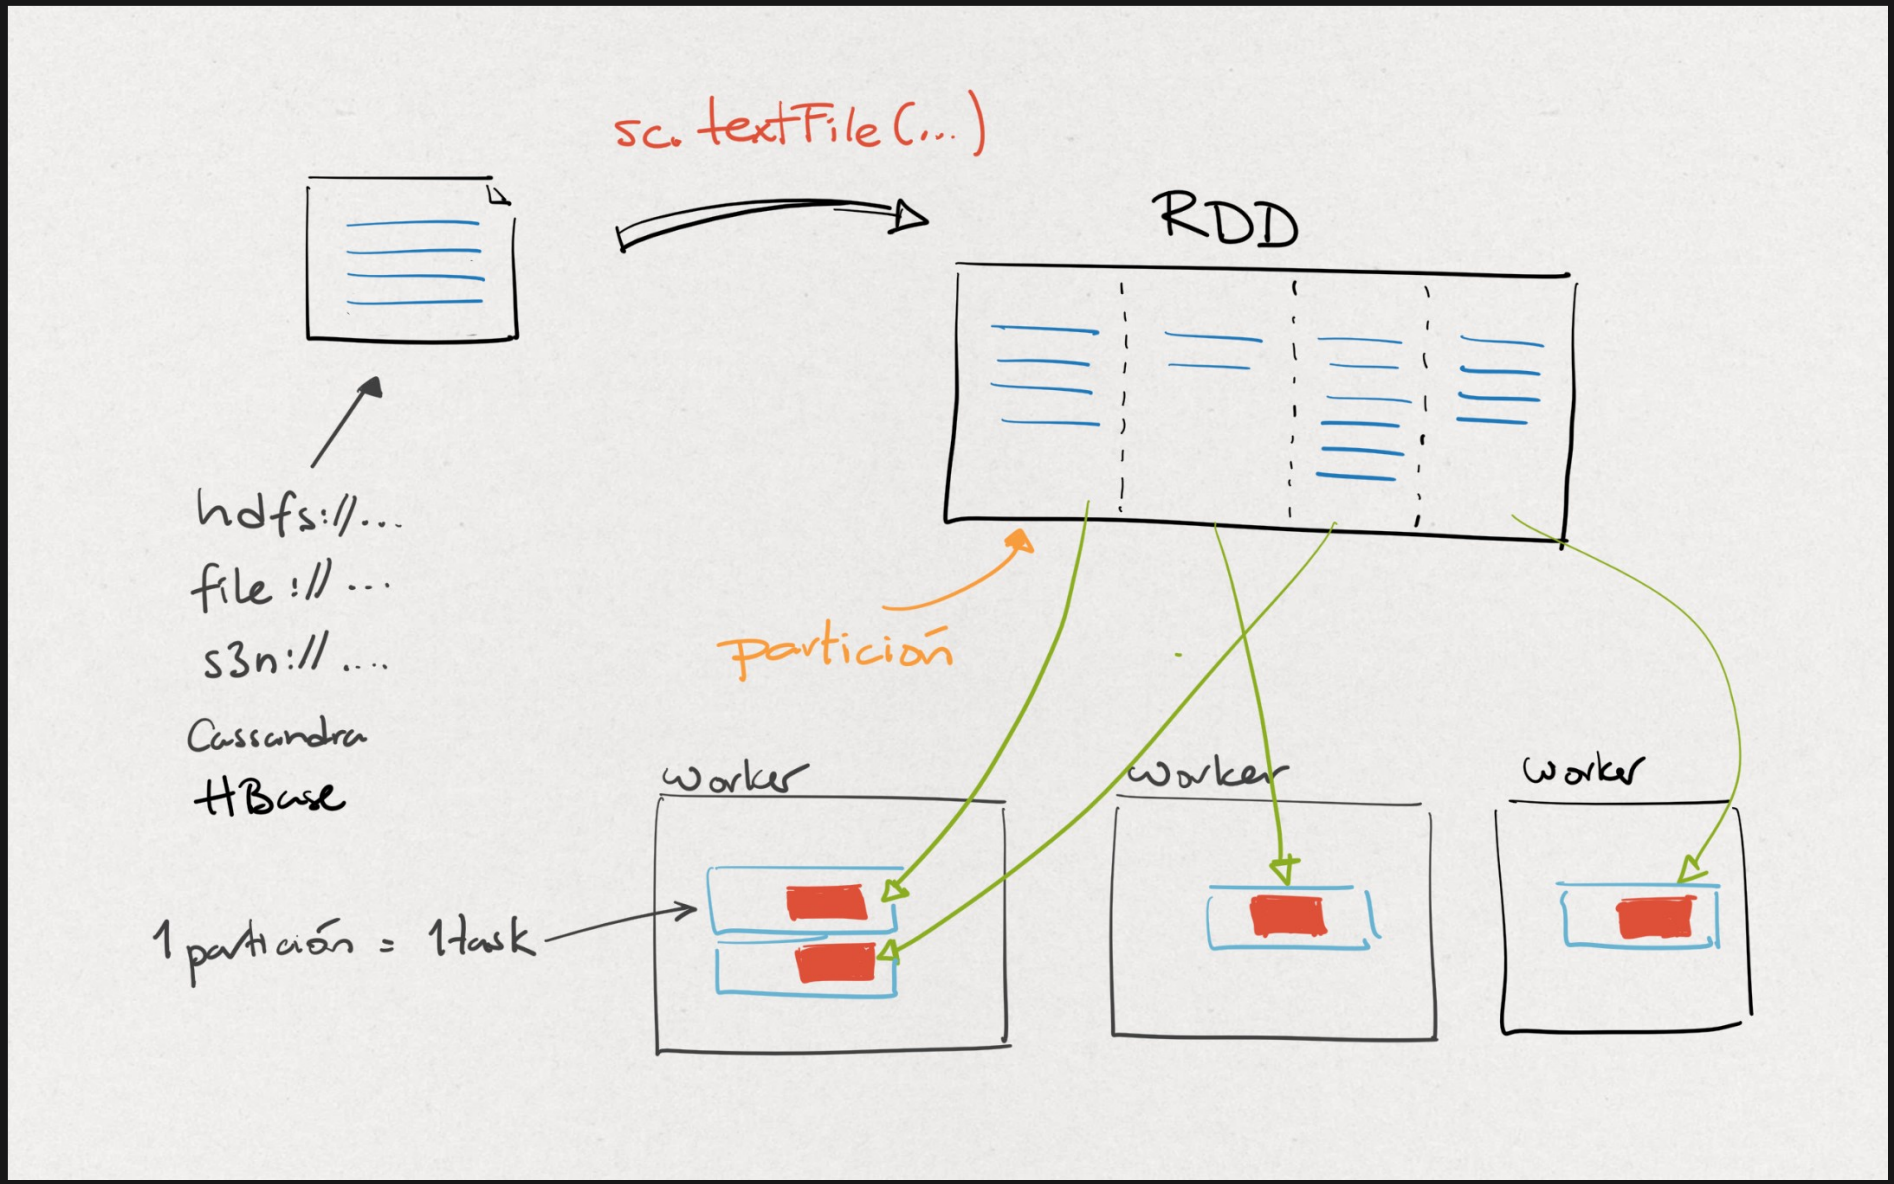
sc.textFile(...)
RDD
hdfs://...
file://...
s3n://...
Cassandra
HBase
partición
worker
worker
worker
1 partición = 1task

Spark RDD: Operaciones

- Soportan dos tipos de operaciones:
  - **Transformaciones**
  - **Acciones**
- Las *transformaciones* construyen un nuevo RDD a partir del anterior.
  - El cual queda guardado en el *linage graph* (DAG)
- Las *acciones* calculan el resultado basado en el RDD.
- La diferencia es que las transformaciones son computadas de manera *lazy* y sólo son ejecutadas hasta la acción.

Spark RDD

Demo

Operaciones

DAG

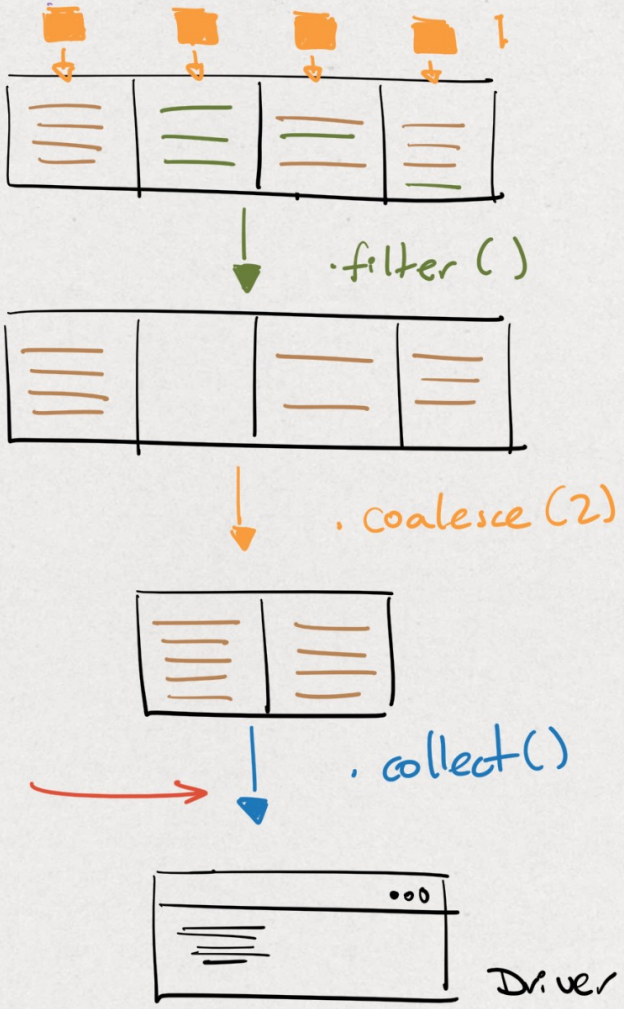
.filter()
.coalesce(2)
¿Aquí se ejecuta el DAG!
.collect()
Driver
¡Cuidado!

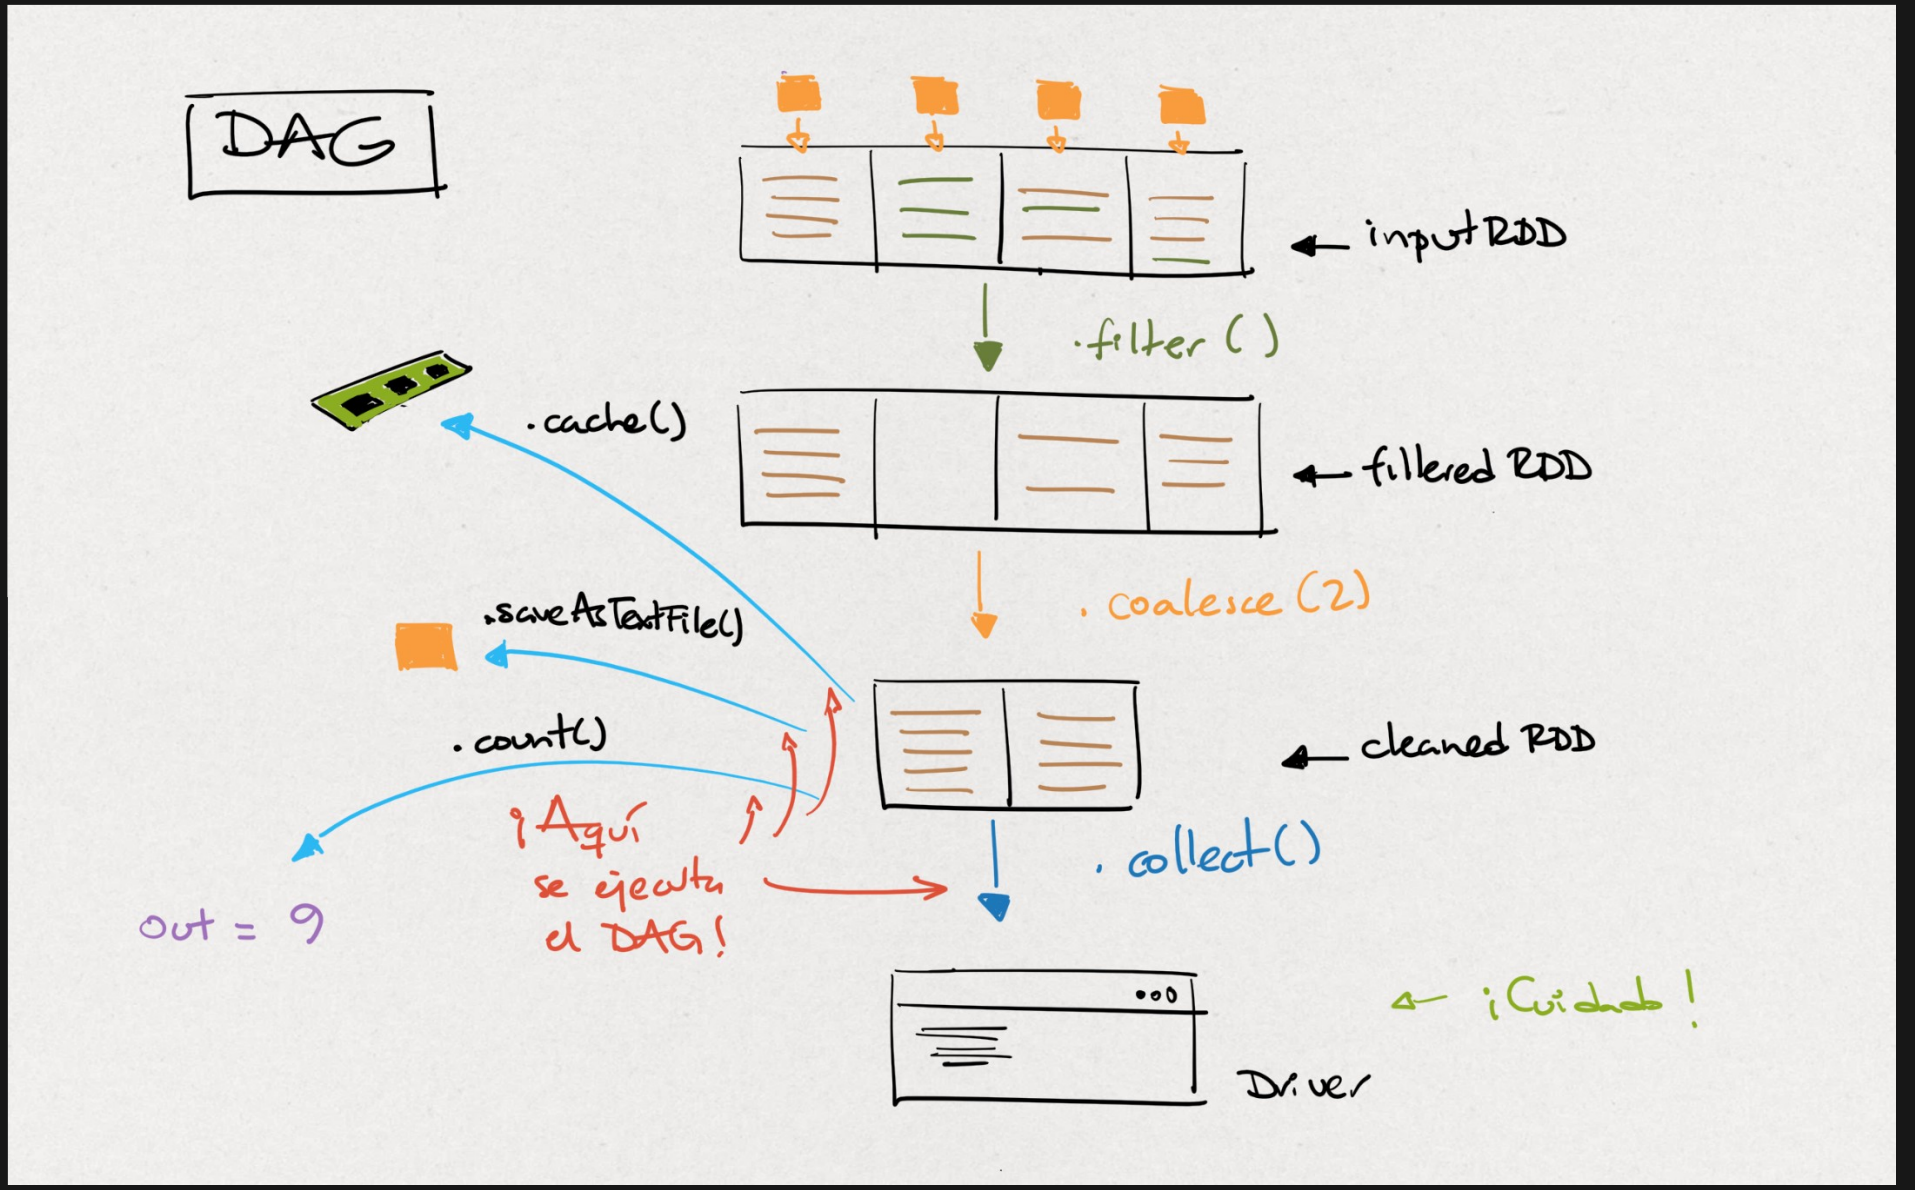
DAG
inputRDD
.filter()
.cache()
filtered RDD
.saveAsTextFile()
.coalesce(2)
.count()
cleaned RDD
¡Aquí se ejecuta el DAG!
.collect()
out = 9
¡Cuidado!
Driver

Transformaciones

Demo

Acciones

Demo

Spark DataFrames

Spark SQL

- Agregado recientemente (2015) a Apache Spark
- Ejecuta *queries* `SQL` o `HiveQL`.
- Agrega una capa de abstracción encima de los RDDs al convertirlos en **Data Frames**, análogos a los usados en R y Pandas.
- Define un `sqlContext` análogo a `sc`

Spark SQL

- Unifica la interfaz para escribir/leer en varios formatos
- `df = sqlContext.read \`
  `.format(“json”)\`
  `.load(“….”)`
- `df = sqlContext.write \`
  `.format(“parquet”)\`
  `.mode(“append”)`
  `.saveAsTable(“….”)`

Spark SQL

- Seleccionar columnas y filtrar
- Realizar `joins`
- Agregaciones
- Funciones analíticas
- Graficación
  - usando `pandas` ó `ggplot`

Spark DataFrames

- Soporta una gran cantidad de formatos de datos y sistemas de almacenamiento.
  - Json, parquet, avro, csv, etc.
- Optimización con Spark SQL Catalyst
  - De hecho son más eficientes que los RDD
- APIs en Python, Java, Scala, R.
- Integrados con toda la infraestructura de Spark.
  - ML, *Streaming*, GraphX, etc.

Spark DataFrames

- Al estar construidas sobre Spark RDD, puedes usar operaciones de RDD sobre un DataFrame, pero no es recomendable, ya que obtendrías un RDD de regreso.
- Los DataFrames (debido al optimizador Catalyst) son mucho más rápidos que los RDDs, además de que esa velocidad ganada es igual en todos los lenguajes.
  - Esto no sucede con los RDDs, un RDD en Scala es más rápido que un RDD en Python.

Spark DataFrames

- Por *default* Spark utiliza el `SQLContext` nativo, pero, si estás conectado a un *cluster* con Apache Hive, puedes utilizar el `HiveContext` en su lugar.
- Esto te permitirá usar todo el `HiveQL`, sus `udf's` y escribir/leer a tablas en Hive.
- En este taller **NO** tenemos un `HiveContext` `-:(`

Spark DataFrames

- Los DataFrames tienen esquema.
  - Se puede ver con `printSchema()`.
  - Spark se encarga de extraerlo (`Parquet`, tabla) o inferirlo (`json`).
- Un DataFrame `Column` es una abstracción, ya que no todas las fuentes están en formato columnar.
- A pesar de la sintaxis, es importante recordar que una `Column` **NO** es igual a un DataFrame

Spark DataFrames

- Al igual que los `RDDs`, los `DataFrames` pueden ser operados mediante transformaciones y acciones.
- Las *Transformaciones* son *lazy* pero contribuyen a la planeación de la ejecución del query, las **Acciones** provocan la ejecución del query.
- Esto último significa que al ejecutarse la acción, Spark lee el data source y los datos fluyen a través del **DAG** generado por el optimizador, al concluir el resultado de la acción se despliega en el `Driver`.

Spark DataFrame

Demo

Spark ML

Spark ML

- Apareció en Spark 1.2
  - `spark.ml`
- Su objetivo es estandarizar una API para algoritmos de aprendizaje de máquina, de tal manera que sea más fácil combinarlos en un *pipeline* o *workflow*.
- Usa Spark DataFrames
  - **IMPORTANTE**: `spark.mlib` usa RDDs, `spark.ml` usa DataFrames.
  - No veremos `spark.mlib`

Spark ML: Transformers

- Es un algoritmo que transforma un DataFrame en otro DataFrame, generalmente agregando una o más columnas.
- Su método más importante es `transform()`
- Incluye *features transformers* y *learning models.*

Spark ML: Transformers

Feature Transformer

- Toma un dataset
- Lee una columna
  - `texto`
- La convierte en una nueva columna de *features* y la agrega al dataset
  - `vectorización del texto`
- Devuelve un dataset nuevo

Learning model

- Toma un dataset
- Lee la columna que contiene los *features*
- Predice las etiquetas para cada vector de *features*
- Agrega esa columna de etiquetas
- Devuelve un dataset nuevo

Spark ML: Estimators

- Es un algoritmo que puede ser ajustado en un DataFrame para producir un **Transformer.**
- Un algoritmo de aprendizaje de máquina es un **Estimator** que entrena en el dataset para obtener un modelo.
- Implementan el método `fit()`.
- La regresión logística es un Estimator e invocando `fit()` entrena un modelo de regresión logística que es un Transformer.

Spark ML: Pipeline

- En aprendizaje de máquina, es común ejecutar los algoritmos en una secuencia para procesar y aprender de los datos.
- Spark ML abstrae este *workflow* en un Pipeline, el cual consiste en una secuencia de Transformers y Estimators.

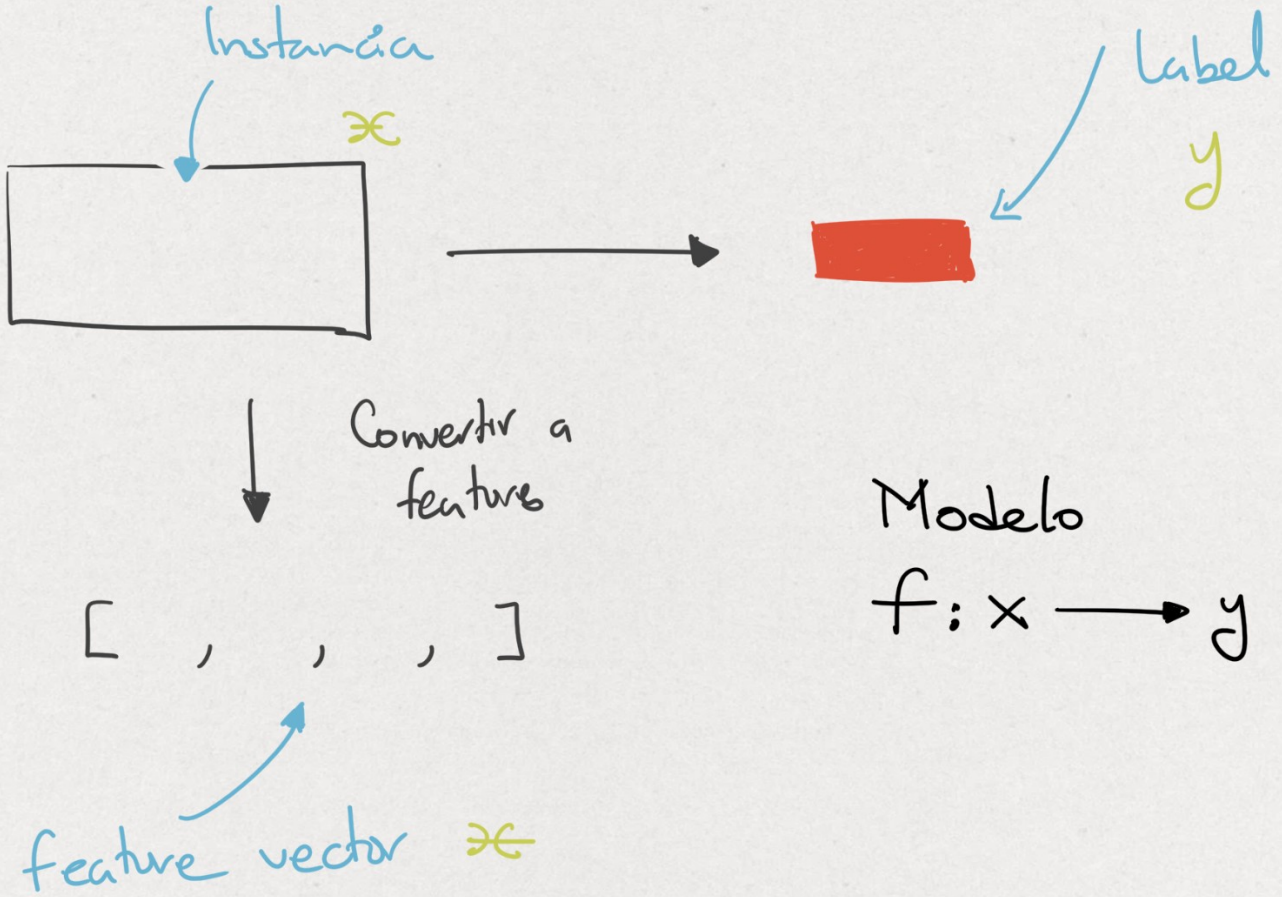
Instancia
x
label
y
Convertir a features
[, , ,]
feature vector
x
Modelo
f: x → y

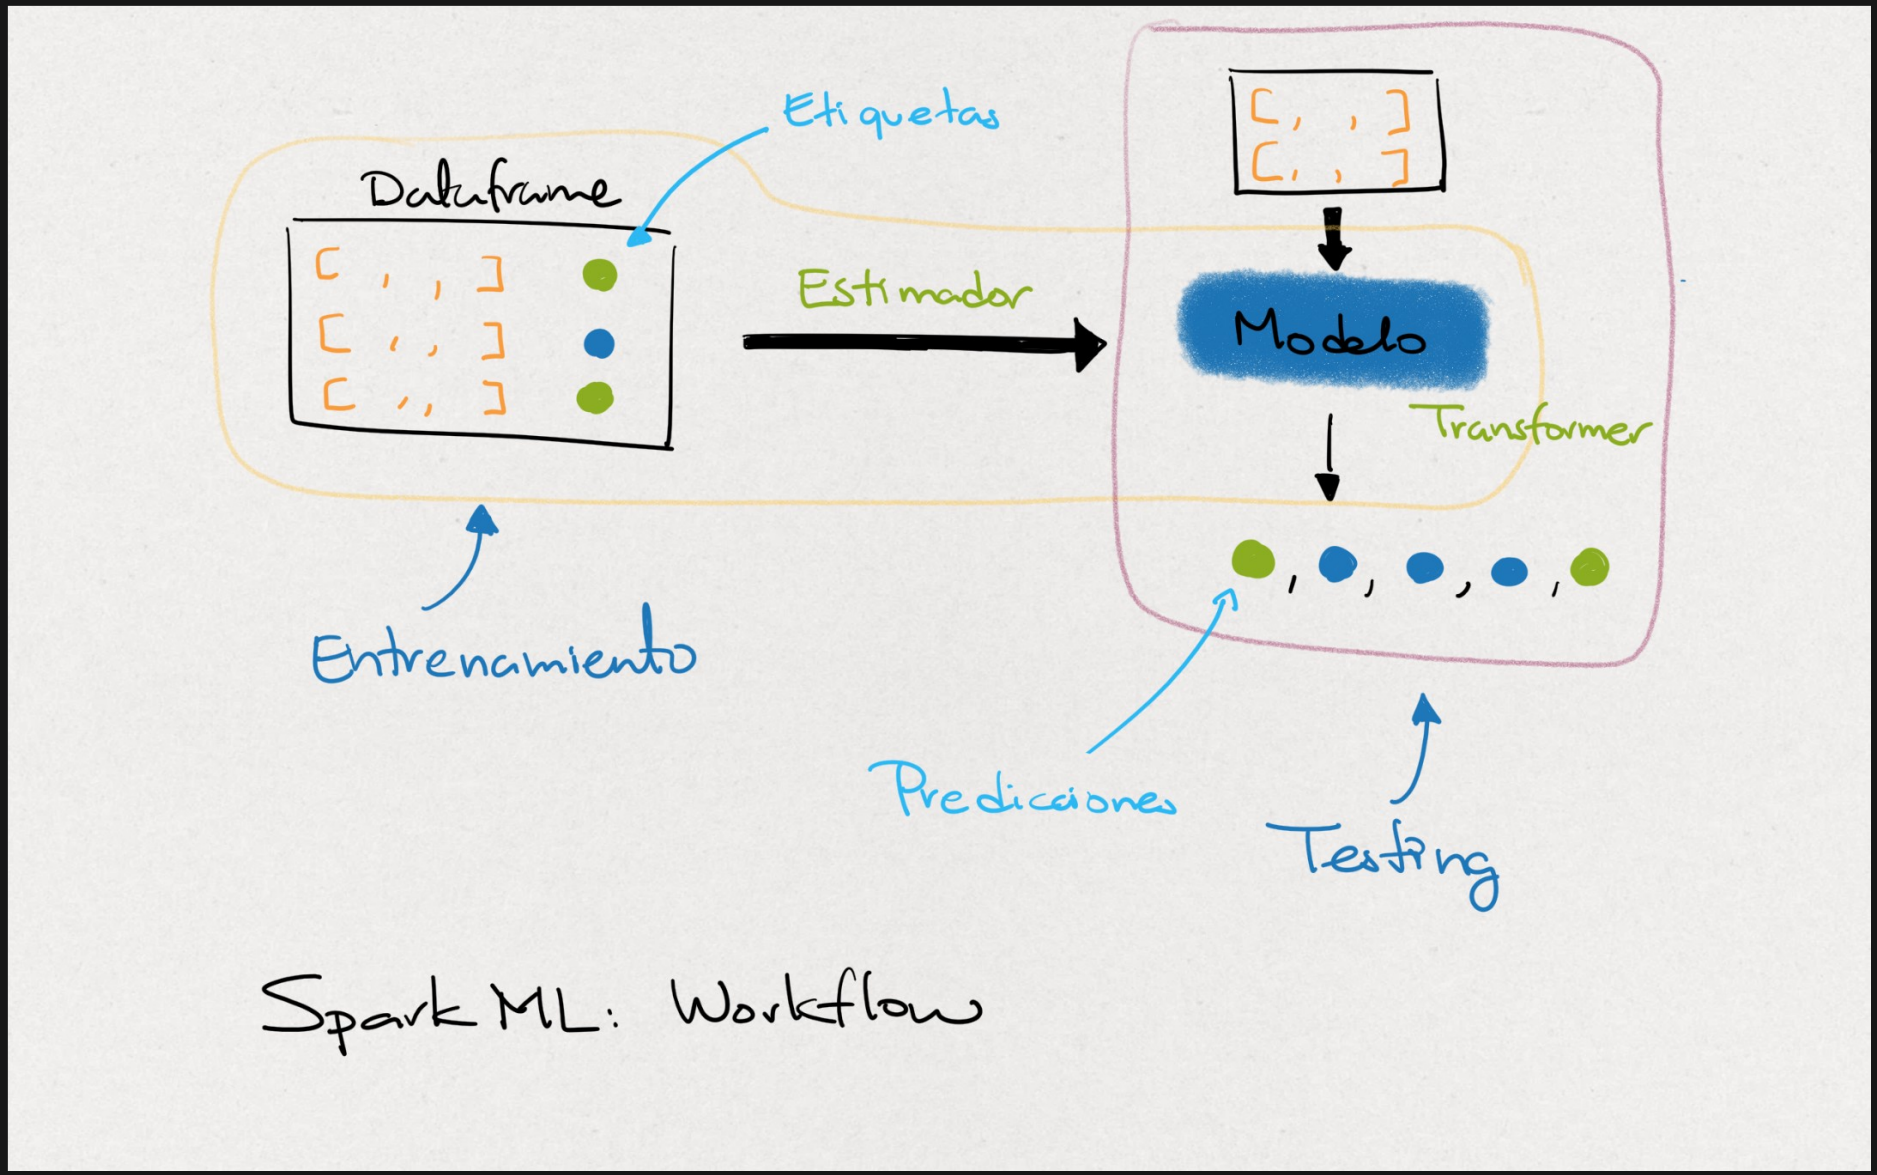

Spark ML: Workflow

Spark ML

Demo

Spark Streaming

Spark Streaming

Demo

Spark GraphX

Spark GraphX

Demo